

Préservation des données

Stéphane Gill

Stephane.Gill@CollegeAhuntsic.qc.ca

Table des matières

Pourquoi préserver les données?	2
Systèmes tolérants aux pannes	2
Mise en réseau des moyens de stockage d'information.....	3
Disque redondant.....	3
Remplacement de disques à chaud.....	5
La sauvegarde des données et la sécurité	5
Stratégie de sauvegarde.....	6
Type de lecteur de bande.....	7
Logiciels propriétaires.....	9
Sauvegarde et restauration – Windows	10
Sauvegarde et restauration – Linux	10
Utilisation de tar et find pour les sauvegardes	10
Lancement Automatique de Processus.....	11
Exemple de stratégie de sauvegarde	11
Exemple de stratégie de sauvegarde différentielle.....	11
Exemple de calcul pour le choix d'un lecteur de bande.....	12
Références	12

Document écrit par Stéphane Gill

© Copyright 2003 Stéphane Gill

Ce document est soumis à la licence GNU FDL.

Permission vous est donnée de distribuer, modifier des copies de ce document tant que cette note apparaît clairement.

Pourquoi préserver les données?

« 50% des entreprises qui perdirent les moyens informatiques nécessaires à leurs affaires pendant dix jours ou davantage ne s'en relevèrent pas. 93% de celles qui n'avaient pas de plan de récupération cessèrent leur activité cinq années plus tard. »

Référence : « Will you be ready when disaster strikes? », PC Week, 6 février 1995.

Les informations constituent généralement le bien le plus précieux d'une entreprise. Aussi leur disponibilité est considérée comme une nécessité.

La disponibilité des données, c'est l'assurance que les données seront utilisables où et quand leurs utilisateurs en auront besoin. Le système de fichiers doit être d'une disponibilité à toute épreuve. Il est souhaitable que le support matériel utilisé pour l'exploitation de fichiers soit lui aussi, à l'abri des pannes. Malheureusement, lorsque la disponibilité des données est compromise suite à une attaque, l'administrateur du système informatique doit être en mesure de restaurer les données.

Dans ce chapitre, les diverses stratégies qui peuvent être mises en œuvre pour préserver les données sont présentées.

Systèmes tolérants aux pannes

Les systèmes tolérants aux pannes mettent en œuvre différentes stratégies pour augmenter leurs disponibilités. Voici quelques-unes de ces stratégies :

- **Résistance** : système conçu pour résister à des conditions extrêmes.
- **Tolérance** : système capable de détecter et de corriger les erreurs avant qu'elles ne se traduisent par des pannes.
- **Redondance** : système conçu avec des systèmes de stockage de l'information redondants et plusieurs points de connexion à l'infrastructure.
- **Remplaçabilité** : système permettant de remplacer tout organe défaillant sans interruption de services.

- **Redémarrage** : système capable de redémarrer automatiquement sans intervention manuelle.
- **Récupérabilité** : Système capable de restaurer ses informations au moment du redémarrage à partir du point d'interruption.

Mise en réseau des moyens de stockage d'information

La mise en réseau des moyens de stockage est une façon de centraliser l'information sur un système à haute disponibilité. Il existe principalement 2 approches :

- NAS (Network Attached Storage);
- SAN (Storage Attached Network).

NAS (Network Attached Storage).

Un NAS est constitué d'un ou plusieurs disques durs montés généralement en RAID, d'une interface réseau, et d'un contrôleur. Un NAS n'est donc pas relié directement à un serveur, c'est une unité de stockage autonome. L'accès au NAS se fait par l'intermédiaire de divers protocoles comme : NFS, SMB/CIFS, http ou https.

Figure

SAN (Storage attached Network).

Dans cette configuration, les disques sont directement attachés à un réseau de stockage *Fibre Channel*. Des serveurs sont reliés à ce réseau de fibres comme présenté à la figure suivante. Contrairement au NAS, la gestion des fichiers est confiée à des serveurs.

Figure

Disque redondant

La technologie RAID (Redundant Array of Independent Disk) permet de construire une unité de stockage à partir de plusieurs disques durs. L'unité ainsi créée a donc une grande tolérance aux pannes ou à une plus grande vitesse d'accès.

Les disques assemblés selon la technologie RAID peuvent être utilisés de différentes façons, appelées niveaux RAID. Il existe 7 niveaux (0 et 6), chacun d'entre eux décrit la manière de laquelle les données sont réparties sur les disques.

Niveau 0

Le niveau RAID-0, appelé *striping* consiste à stocker les données en les répartissant sur l'ensemble des disques du système RAID. Il n'y a donc pas de redondance, et aucune tolérance aux pannes. En effet, en cas de défaillance de l'un des disques, l'intégralité des données réparties sur les disques sera perdue.

Toutefois, étant donné que chaque disque du système RAID a son propre contrôleur, cela constitue une solution offrant une vitesse de transfert élevée.

Niveau 1

Le niveau 1 a pour but de dupliquer l'information à stocker sur plusieurs disques, on parle donc de *mirroring* pour désigner ce procédé.

On obtient ainsi une plus grande sécurité des données, car si l'un des disques tombe en panne, les données sont sauvegardées sur l'autre. D'autre part, la lecture peut être beaucoup plus rapide lorsque les deux disques sont en fonctionnement. Enfin, étant donné que chaque disque possède son propre contrôleur, le serveur peut continuer à fonctionner même lorsque l'un des disques tombe en panne.

Niveau 2

Le niveau RAID 2 propose un contrôle d'erreur par code de *Hamming*. Ce niveau est désormais désuet car cette technologie est directement intégrée dans les contrôleurs de disques durs.

Niveau 3

Le niveau 3 propose de stocker les données en les répartissant sur plusieurs disques et de dédier un des disques au stockage d'un bit de parité.

De cette manière, si l'un des disques venait à défaillir, il serait possible de reconstituer l'information à partir des autres disques.

Niveau 4

Le niveau 4 est semblable au niveau 3. La différence se trouve dans la façon de calculer la parité. Le calcul se fait sur les secteurs (blocs) et non sur les bits et, comme pour le niveau 3, la parité est stockée sur un disque dédié. La valeur du facteur d'entrelacement est donc différente de celle du système RAID 3.

Niveau 5

Le niveau 5 est similaire au niveau 4, c'est-à-dire que la parité est calculée au niveau d'un secteur, mais répartie sur l'ensemble des disques du système RAID 5.

De cette façon, RAID 5 améliore grandement l'accès aux données aussi bien en lecture qu'en écriture.

Niveau 6

Le niveau 6 définit l'utilisation de 2 fonctions de parité, et donc leur stockage sur deux disques dédiés. Ce niveau permet ainsi d'assurer la redondance en cas d'avarie simultanée de deux disques. Cela signifie qu'il faut au moins 4 disques pour mettre en oeuvre un système RAID-6.

Remplacement de disques à chaud

hot-swap

La sauvegarde des données et la sécurité

L'information présentée dans les différents chapitres avait pour but de prévenir les menaces potentielles. Cependant, il est presque inévitable que, à un moment donné, tout système soit compromis. Lorsqu'un système est compromis, une des préoccupations majeures est de restaurer ce système.

Dans les sections suivantes, diverses stratégies, techniques et logiciels de sauvegarde et de restauration de données sont présentées.

Stratégie de sauvegarde

Il n'est pas suffisant de copier toutes les données d'un disque sur un ruban magnétique et de penser que vous avez résolu le problème de sauvegarde. Il est essentiel de planifier vos sauvegardes. Les quatre étapes d'une stratégie de sauvegarde sont :

- la planification;
- la rotation;
- la vérification;
- la conservation.

La planification

La planification est l'étape où les données à sauvegarder, la fréquence des sauvegardes (jour, semaine, mois) et le type de sauvegarde sont identifiés. Il existe 3 types de sauvegarde :

- **complète** : sauvegarde l'ensemble des fichiers du disque.
- **incrémentale** : ne sauvegarde que les fichiers qui ont été modifiés depuis la dernière sauvegarde. Une restauration nécessite donc de récupérer d'abord une sauvegarde complète et ensuite de reprendre les restaurations incrémentales.
- **différentielle** : sauvegarde tous les fichiers modifiés depuis la dernière sauvegarde complète.

La rotation

Si la sauvegarde incrémentale sur 10 tapes avoir 20 ou 30 tapes.

La vérification

Après chaque sauvegarde vérifier son fonctionnement.

Comment? Pas en regardant les fichiers de log, en récupérant 1 ou 2 fichiers.

La conservation

- coffre-fort;
- à la banque;

- dans un autre local.

Type de lecteur de bande

Dans cette section, les technologies DAT, 8 mm, DLT et super DLT sont brièvement présentées. Toutes ces technologies sont généralement disponibles avec une interface SCSI et peuvent être intégrées à des chargeurs de bande.

Cassette DAT

La technologie DAT a été au départ développée pour les cassettes audio digitales. En 1998, HP et Sony définirent le standard DDS (Digital Data Storage) basé sur les cassettes DAT.

Les cassettes DAT existent en 2 formats: DDS et DataDAT. Le système DDS est le plus courant.

Norme	Capacité	Capacité compressée	Taux de transfert	Taux de transfert compressés
DDS	2Go	-	55 KBps	-
DDS-1	2 Go	4 Go	0.55 MBps	1.1 MBps
DDS-2	4 Go	8 Go	0.55 MBps	1.1 MBps
DDS-3	12 Go	24 Go	1.1 MBps	2.2 MBps
DDS-4	20 Go	40 Go	2.4 MBps	4.8 MBps

Cartouche 8 mm.

Les cartouches 8 mm ont été développées au début pour la vidéo de haute qualité. Elles sont similaires aux cartouches DAT mais elles offrent généralement une plus grosse capacité de stockage.

Deux standards sont actuellement utilisés suivant le système de compression: Exabyte Corporation et son standard 8 mm et le mammoth développé par Seagate et Sony.

Standard	Capacité	Capacité compressée	Taux de transfert
Standard 8mm	3.5 Go	7 Go	32 MB/min

Standard 8mm	5 Go	10 Go	60 MB/min
Standard 8mm	7 Go	14 Go	60 MB/min
Standard 8mm	7 Go	14 Go	120 MB/min
Mammouth	20 Go	40 Go	360 MB/min

D'autres technologies se développent actuellement dans ces familles. Le tableau ci-dessous présente les technologies AIT :

Norme	Capacité	Capacité compressée	Taux de transfert	Taux de transfert compressés
AIT-1	35GB	90GB	4MBps	10MBps
AIT-2	50GB	130GB	6MBps	15.6MBps
AIT-3	100GB	260GB	12MBps	31.2MBps

Cartouche DLT

Cette technologie a été développée par DEC dans les années 1980 pour ses mini-ordinateurs VAX. Les cartouches DLT sont plus petites que les cartouches 8 mm et la durée de vie des têtes de lecture est de beaucoup supérieure à celle des lecteurs DAT.

Standard	Capacité	Capacité compressée	Taux de transfert
DLT2000	15 Go	30 Go	2.5MBps
DLT4000	20 Go	40 Go	3MBps
DLT7000	35 Go	70 Go	20MBps

Super DLT

Les cartouches Super DLT sont commercialisées par Quantum. Tel que présenté dans le tableau suivant, les cartouches Super DLT ont une capacité supérieure au cartouche DLT.

Norme	Capacité	Capacité compressée	Taux de transfert	Taux de transfert compressés
-------	----------	---------------------	-------------------	------------------------------

SDLT 220	110GB	220GB	11MBps	22MBps
SDLT 320	160GB	320GB	16MBps	32MBps
SDLT 640	320GB	640GB	32MBps	64MBps
SDLT 1280	640GB	1.28TB	50MBps	100MBps
SDLT 2400	1.2TB	2.4TB	100MBps	200MBps

Chargeurs de bandes

Les chargeurs de bandes sont des équipements de sauvegarde dans lesquels il est possible d'insérer plusieurs cartouches. Ces systèmes permettent donc de changer les cartouches sans intervention de l'administrateur.

Logiciels propriétaires

Il existe de nombreux logiciels commerciaux qui permettent d'effectuer la sauvegarde et la restauration de données. Voici la liste de quelques produits disponibles pour un environnement Windows :

- Computer Associates' AccServe;
- Legato Networker;
- Veritas' Backup Exer
- Veritas' Netbackup.

Quelques produits sont aussi disponibles sous Linux :

- PERFECTBACKUP+ (Merlin Software)
- BRU (Enhanced Software Corp)
- ARKEIA (Knox)
- QUICK RESTORE (Workstation Solutions)

Sauvegarde et restauration – Windows

Trouver image

Sauvegarde et restauration – Linux

Les systèmes UNIX/LINUX disposent au minimum de 4 commandes pour la sauvegarde des données :

- *tar*
- *cpio*
- *dd*
- *dump, restore*

De ces 4 commandes, seules les 2 premières sont d'utilisation courante : *tar* et *cpio*.

Utilisation de tar et find pour les sauvegardes

On commence par rechercher les fichiers modifiés dans les dernières 24 heures :

```
find / -mtime -1 \! -type d -print > /tmp/liste.jour
```

On archive sur disquette:

```
tar -cv -T /tmp/liste.jour -f /dev/fd0
```

Pour des sauvegardes sur bandes, on pourra indiquer comme fichier de périphérique */dev/rft0* (premier lecteur de bandes qui se connecte à la place d'une unité de disquettes), */dev/st0* (premier lecteur de bandes SCSI), */dev/nrft0* (pareil que */dev/rft0* sans rembobinage à la fin de la sauvegarde), */dev/nrst0* (pareil que */dev/st0* sans rembobinage à la fin de la sauvegarde).

Pour rembobiner la bande, taper la commande :

```
mt -f /dev/nrst0 rewind
```

et pour retendre la bande (aller-retour complet, ce qui assure un défilement régulier) :

```
mt -f /dev/nrst0 reten
```

Pour aller au fichier suivant, taper :

```
mt -f /dev/nrst0 fsf 1
```

et pour aller deux fichiers plus loin (à partir de la position courante) :

```
mt -f /dev/nrst0 fsf 2
```

Il est nécessaire de bien positionner la bande avant d'utiliser tar (et après l'avoir utilisé, car la bande ne se trouve pas exactement en fin de fichier).

Lancement Automatique de Processus

Le lancement automatique de processus, ou même de commandes, est effectué grâce au démon `crond`. Celui-ci va explorer le fichier `/etc/crontab` dans lequel sont référencées toutes les actions à engager.

Il est possible de lancer des processus de deux manières différentes :

- lancement différé d'un processus grâce à la commande `at` ;
- lancement cyclique d'un processus grâce à la commande `crontab`.

Exemple de stratégie de sauvegarde

Exemple de stratégie de sauvegarde différentielle

Voici un exemple de stratégie de sauvegarde dans un environnement où il n'y a pas d'activité la nuit et la fin de semaine. Dans ce cas, les applications ne tournent pas de nuit, d'où l'intérêt de faire les sauvegardes durant cette période.

Semaine 1	Lundi	Mardi	Mercredi	Jeudi	vendredi	samedi	dim.
Type	Diff.	Diff.	Diff.	Diff.	Diff.	Compl.	

Heure	21h	21h	21h	21h	21h	20h	
Bande	Lu1	Ma1	Me1	Je1	Ve1	Com1	

Semaine 2	Lundi	Mardi	Mercredi	Jeudi	vendredi	samedi	dim.
Type	Diff.	Diff.	Diff.	Diff.	Diff.	Compl.	
Heure	21h	21h	21h	21h	21h	20h	
Bande	Lu2	Ma2	Me2	Je2	Ve2	Com2	

Exemple de calcul pour le choix d'un lecteur de bande

Considérons un système de stockage équipé de 5 disques de 100 Go. Les disques sont utilisés à 73%. On dispose d'un lecteur de bande dont la capacité des cartouches est de 160 Go et le taux de transfert de 16 MBps.

- Combien faut-il de cassettes pour faire une sauvegarde complète?
- Combien faut-il de temps pour faire une sauvegarde complète?
- Évaluer la taille des fichiers modifiés en 24 heures.
- Combien faut-il de cassettes pour faire une sauvegarde incrémentale?

Références

Stefen Norberg, « Securing Windows NT/2000 Servers for the Internet », O'Reilly, 2001.

Eric Maiwald, « Sécurité des réseaux », Campus press, 2001.

Aron Hsiao, « Sécurité sous Linux », Campus press, 2001.

« Red Hat Linux 9 : Red Hat Linux Security Guide », Red Hat Inc., 2002.

« Red Hat Linux 9 : Guide de référence Red Hat ». Red Hat Inc., 2003.

Simon Guillem-Lessard, « Cryptographie Tutorial », Projet de fin d'étude, Université du Québec à Trois-Rivières, 2002.